強化 RAG 與提示工程之大型語言模型在特殊教育 IEP 生成任務的應用

Enhancing RAG and Prompt Engineering to Enhance LLM-based Text Generation in Special Education

張若薇[1]　林家賢[2]　張瑞顯[3]　李宜蓁[3]
[1]Institute of Computer Science and Engineering
[2]The Graduate Degree Program of Artificial Intelligence
[3]Institute of Artificial Intelligence Innovation
National Yang Ming Chiao Tung University
{helloworld.cs13, ljx901024.ee13, ruei.ii14, azure.ii14}@nycu.edu.tw

摘要

本專案建立一套輔助撰寫個別化教育計畫（Individualized Education Program, IEP）的生成系統，將 Large Language Models（LLM）導入 IEP 撰寫流程，並以 Retrieval-Augmented Generation（RAG）架構整合法規、課綱及教材，使生成內容能基於特殊教育領域專業知識進行回答。在 Retrieval 階段，透過設計 Chunking 方法與 Rerank 機制強化檢索效果；在 Generator 階段則導入提示工程（Prompt Engineering）以規範角色設定、推理流程與輸出結構。最終在消融實驗與人工評測結果顯示，此架構能有效提升 IEP 撰寫效率，並生成可應用於教育現場的計畫內容，進而減輕特殊教育教師的文書工作負擔，展現出此成果於特殊教育場域中的應用潛力。

1 Introduction

1.1 Motivation

在教育現場中，特教老師會為每位身心障礙學生撰寫個別化教育計畫（Individualized Education Program, IEP），以規劃學生的學習目標、教學策略與評量方式，確保教育內容能符合學生的個別需求。然而，IEP 的撰寫過程繁瑣且耗時，造成教師在文書與行政作業上的負擔過重，即使嘗試運用大型語言模型（Large Language Models, LLMs）輔助撰寫，仍因其缺乏對特教領域知識與專業術語的理解，生成內容常出現幻覺、不符教材或語意過於籠統等問題，難以直接協助教師完成 IEP。目前在特殊教育領域缺乏專用的語言模型，但實務上有高度需求，其發展將對學習輔助與教師支援產生重大價值。

1.2 Critical Challenges

1. LLM 缺乏對特教領域知識的理解，生成內容常出現錯誤、幻覺。
2. 現有特教資料量少且多為非結構化文本，不利於模型微調。
3. IEP 撰寫需具備明確步驟與結構，現有模型缺乏分階段生成與內容組織能力。

1.3 Problem Statement

1. 如何再不做 Fine-Tune 的情況下，讓 LLM 掌握特教領域知識，例如導入 RAG。
2. 如何將非結構化文本內容正確擷取，再透過 RAG 架構進行檢索。
3. 如何在提示長度有限的情況下，兼顧教育知識專業及生成架構。

2 Related Work

2.1 HiChunk: Evaluating and Enhancing Retrieval-Augmented Generation with Hierarchical Chunking [1]

傳統固定長度切塊（fixed-size chunking）容易造成語意破碎，進而降低檢索品質，本篇論文提出 Hierarchical Chunking 方法，採用層次式文件切塊策略，優先依據章節結構與語意單元分段，再進行細粒度切塊，使每個 chunk 在嵌入前具備更好的語意密度與脈絡一致性。此策略特別適用長文本資料，能有效提升檢索階段的 recall 與相關性。

2.2 M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation [2]

但本專案主要參考其重排序（reranking）設計概念，Cross-Encoder 式評分機制提供更精確的語意判斷，使其在不同長度或切割方式的 chunk 中，仍能維持穩定且精準的語意匹配表現，提升候選文件在語意上的排序精準度。

2.3 Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models [3]

Qwen3 提供強化的中文語意理解能力，並支援 instruction-aware 向量化，使 Query embedding 能根據任務需求調整語意方向，提升檢索精準度。本專案採用 Qwen3 Embedding Model 向量模型。

2.4 ReAct: Synergizing Reasoning and Acting in Language Models [4]

ReAct 方法所提出的透過思考（Thought）→ 動作（Action）→ 觀察（Observation）→ 最終回答（Final Answer）四步驟流程，使模型生成內容能明確展示思考過程，依據檢索結果調整回答降低幻覺（hallucination）發生，產生更具有架構及結構依據的 IEP 內容，應用於本專案提示工程（Prompt Engineering）的核心架構。

3 Method

在本次的專案中會由兩大核心模組組成：Retriever（檢索器）與 Generator（生成器），如圖 1所示。

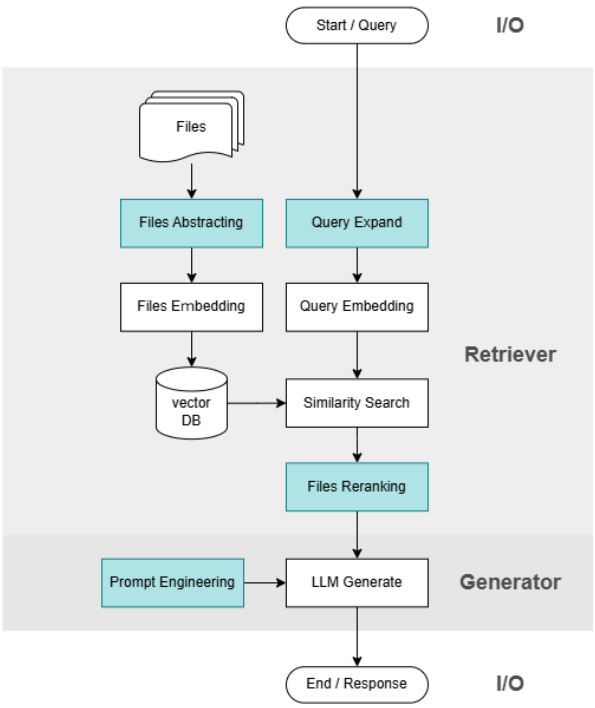


圖 1: 本專案系統架構圖（來源：自行繪製）

3.1 Retriever（檢索器）

3.1.1 File Abstracting / Chunking Method

在本專案中，為提升 Retrieval-Augmented Generation（RAG）系統於法律文件場景下的檢索品質與回答正確性，我們針對文件前處理階段中的 **File Abstracting 與 Chunking 方法**進行了系統性的比較與實驗設計。本節主要參考 HiChunk: Evaluating and Enhancing Retrieval-Augmented Generation with Hierarchical Chunking [1] 一文所提出的概念，並實作與評估三種常見的文件切塊策略，包含固定長度切塊、重疊式切塊以及層次式文件切塊。

- **固定長度切塊（Fixed-size Chunking）：**
  固定長度切塊為最直觀且實作成本最低的方法，其作法為依據預設的 token 或字數上限，將文件切分為多個等長區塊。然而在實際應用於法律與法規文件時，我們觀察到此方法存在明顯缺陷。由於切割位置完全依賴長度限制，極易在條文敘述尚未完整結束時即被截斷，導致語意在無預警的情況下中斷。此問題會使模型在檢索或生成回答時，僅接收到不完整的法律條文或規範說明，進而產生錯誤理解或推論偏差。因此，固定長度切塊並不適合語意結構高度依賴上下文連貫性的法律文本。

- **重疊式切塊（Overlapping Window）：**
  為緩解固定長度切塊造成的語意斷裂問題，本專案進一步採用了重疊式切塊方法。該方法在相鄰 chunk 之間保留一定比例的重疊內容，使關鍵語句即使位於切割邊界附近，仍能在至少一個 chunk 中以完整形式被保留。實驗結果顯示，Overlapping Window 能有效降低語意被截斷所造成的資訊遺失，並在不顯著增加檢索噪音的前提下，提升模型對法律條文上下

文的理解能力。相較於 Fixed-size Chunking，此方法在法律文件場景中展現出更穩定且可預期的表現。

- **層次式文件切塊（Hierarchical Document Chunking）：**
  此外，本專案亦嘗試實作 HiChunk 論文中所提出的層次式文件切塊方法，期望利用文件的章節、條款或段落結構，進行自上而下的分層切割。然而在實際應用於法律類型文件時，我們發現此方法的效果並不如預期。雖然法律文件本身已具備高度結構化特性，但實際條文內容中仍存在大量跨段落的語意依賴，使得即便依照層級切割，仍難以避免在某些關鍵位置發生語意被切開的情況。
  在此過程中，我們亦嘗試讓文件先經過地端語言模型進行文字格式整理（例如條文重排、段落標準化），再進行層次式切塊。然而實驗結果顯示，即使經過前處理整理，法律文件仍無法穩定地被切分為完全語意獨立的層級單元，因此整體效益有限。

- **文件摘要策略的嘗試與取捨：**
  在研究初期，我們亦曾嘗試於 chunking 後引入地端模型進行摘要，期望透過濃縮內容來降低語意斷裂對模型理解的影響。然而實際觀察發現，摘要過程雖可改善語句連貫性，但同時也不可避免地刪減了部分細節性資訊。對於法律文件而言，這類被省略的細節往往具有關鍵法定意義，可能直接影響最終回答的正確性與可驗證性。因此，本專案最終未採用摘要式 File Abstracting 作為正式流程的一部分。

- **總結：**
  綜合上述實驗與分析結果，在法律文件導向的 RAG 系統中，**重疊式切塊（Overlapping Window）在語意完整性與實務穩定性之間取得最佳平衡**。相較於 Fixed-size Chunking 能有效減少語意斷裂風險，且相較於 Hierarchical Document Chunking 不依賴文件結構假設，更能適應實際法規文本的複雜語意關係。因此，本專案最終選擇 Overlapping Window 作為 File Abstracting 與 Chunking 的主要方法。

3.1.2 Embedding with Qwen3

在 Retrieval-Augmented Generation（RAG）系統中，Embedding 模型的選擇與設計直接影響檢索階段的召回品質與語義對齊效果。本專案在 Embedding 模組中，參考 Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models [3] 一文，採用 **Instruction-aware Embedding Model** 作為核心語義表示方法。

- **模型選擇與設計考量：**
  本專案選用 **Qwen3 Embedding（0.6B）**作為向量化模型，其主要原因如下：

  1. **屬於目前文本嵌入任務中的 SOTA 方法**
     Qwen3 Embedding 在多項中英文語義檢索與排序任務中展現出優異表現，特別適合 RAG 與法律文本等高語義精準度需求的應用場景。
  2. **模型規模小、推論成本低**
     在僅 0.6B 參數的情況下，即可提供接近大型 embedding 模型的效果，對於需要在地端或資源受限環境中部署的系統具有高度實務價值。

3. **Instruction-aware 設計支援多任務語義對齊**
   該模型能透過指令（Instruction）調整語義空間，使同一模型可因應不同下游任務需求，有更高的檢索彈性。

- **Embedding 策略與實作方式：**
  在實際應用中，本專案針對 **Query 與 File** 採取不同的 Embedding 策略，以符合 Instruction-aware 模型的設計理念。

  1. **Query Embedding**
     對於使用者查詢（Query），本專案採用**指令式嵌入（Instruction-based Embedding）**，其格式如下：

     ```
     {Instruction} {Query} <|endoftext|>
     ```

  2. **File Embedding**
     相對地，對於文件內容，本專案在完成前述 Chunking 流程後，不額外加入任何 Instruction，而是直接將 chunk 後的原文輸入模型進行 Embedding。此設計有助於維持文件語義的完整性，避免因指令干預而改變原始法律條文的語意結構。

- **Instruction-aware Embedding 的優點分析：**
  採用 Instruction-aware Embedding 模型帶來以下幾項明顯優勢：

  1. **單一 Embedding 模型可支援多任務**
     透過調整 Instruction，即可在檢索、排序、匹配等不同任務間共享同一模型，降低系統整體複雜度。
  2. **可依任務需求調整語義空間**
     Instruction 提供一種顯式控制語義對齊方式的機制，使 Query 表示能更貼近特定任務的檢索目標。
  3. **對中文與法律語境具有良好適應性**
     Qwen3 Embedding 在中文語料上的表現穩定，特別適合法律、政策與規範類文件中常見的長句與專業用語。

- **潛在限制與風險：**
  儘管 Instruction-aware Embedding 具備高度彈性，其設計亦帶來部分潛在風險：

  1. **Instruction 增加語義變異性**
     不同 Instruction 設計可能導致 Query 向量分布產生差異，增加檢索結果不穩定的風險。
  2. **Instruction 設計不當可能影響 Recall**
     若 Instruction 過於狹隘或與實際文件語義不匹配，可能使 Query 偏離正確的語義空間，進而降低 Recall。

  因此，在實作上需對 Instruction 設計保持一致性與簡潔性，避免過度引導模型產生非預期的語義偏移。

- **總結：**
  綜合效能、模型規模與語義控制能力考量，本專案最終採用 **Qwen3 Embedding（0.6B）**作為 RAG 系統的嵌入模型，並透過「Query 使用 Instruction、File 不使用 Instruction」的策略，在語義對齊能力與檢索穩定性之間取得良好平衡。

3.1.3 Vector Database with FAISS

在完成 Chunking 與 Embedding 後，使用了 **FAISS（Facebook AI Similarity Search）**建立向量資料庫，以支援大規模向量的高效率相似度搜尋，作為 RAG 系統中檢索階段的核心元件。

- **向量資料庫建構流程：**
  整體流程如下：

  1. **Embedding**
     所有 Query 與文件 Chunk 皆透過 Qwen3 Embedding 模型轉換為高維語義向量，作為後續相似度計算的基礎。
  2. **向量資料庫建立**
     使用 FAISS 所提供的 IndexFlatIP 作為向量索引結構。IndexFlatIP 為精確搜尋（Exact Search）方法，不進行向量壓縮或近似，能在資料規模可控的情況下，保證檢索結果的正確性與穩定性。
  3. **相似度計算方式**
     為使內積等價於 **Cosine Similarity**，在建立索引與查詢前，對所有 embedding 向量進行 L2 normalization。經正規化後，IndexFlatIP 所計算之內積值即可視為 cosine similarity，用以衡量 Query 與文件 Chunk 之間的語義相似程度。

- **檢索與候選文件選取：**
  在實際檢索階段，系統會針對每一筆 Query 向量，於 FAISS 向量資料庫中執行 cosine similarity 搜尋，並取相似度最高的 Top-100 的 Chunk 作為初步候選集合。此設計有以下考量：

  1. **兼顧 Recall 與後續排序彈性**
     相較於直接取較小的 Top-K，先保留較大的候選集合可降低漏檢風險，確保相關的 Chunk 都能進入 Reranking 模組。
  2. **為 Reranking 階段提供足夠語義多樣性**
     Top-100 候選文件將進一步送入 Reranking 模組，以進行更精細的語義判斷與排序，提升最終回答品質。

- **方法選擇說明：**
  選擇 FAISS IndexFlatIP 作為向量資料庫的主要原因包括：

  1. **搜尋結果穩定且可重現**，適合實驗與法律應用場景
  2. **與我們的 Embedding 方法高度相容**，能準確反映語義距離
  3. **實作簡單、效能可預期**，在中小規模文件庫下具備良好效率

- **總結：**
  綜合而言，本專案透過 **Qwen3 Embedding + FAISS IndexFlatIP（Cosine Similarity）**的組

合，建立一套高效率且語義一致的向量檢索機制，並以 Top-100 作為候選文件集合，為後續 reranking 與生成階段提供可靠的輸入基礎。

3.1.4 Reranking

在向量資料庫檢索階段中，透過 FAISS 以 cosine similarity 取得 Top-100 候選文件 Chunk。然而，由於 embedding-based 檢索主要衡量語義相似度（semantic relevance），仍可能包含語義相近但實際上可能無法支撐推理或回答需求的文件。因此，本專案在檢索後加入 **Reranking 階段**，對候選文件進行更精細的相關性排序，以提升最終回答品質。
本專案嘗試並比較了兩種不同架構的 Reranker，分別為 **Qwen3 4B（LLM-based classifier）**與 **BGE m3 v2（Encoder-only Transformer）**。

- **方法一：Qwen3 4B Reranker（LLM-based Classifier）**
  第一種方法採用 **Qwen3 4B** 作為基於大型語言模型的分類式 Reranker。該模型將 Query 與 Document 作為輸入，並以二元分類的方式判斷文件是否能有夠有效的回答 Query。

  其打分方式可表示為：

$$\text{score}(q, d) = \frac{e^{P(\text{yes}|q,d)}}{e^{P(\text{yes}|q,d)} + e^{P(\text{no}|q,d)}}$$

  此方法的主要特性包括：

  – 能結合語言模型的推理能力，較偏向 **reasoning relevance**，而非單純的語義相似度
  – 可依據不同任務設計對應的 prompt，具備高度彈性
  – 對於需要跨段推理或語意判斷的任務具潛在優勢

  然而，在實際實驗過程中，我們也觀察到以下限制：

  – 模型表現高度依賴 prompt 設計，排序結果穩定性較低
  – 計算成本與延遲相對較高，不利於大規模候選文件排序
  – 排序結果可能因文件內容過於相似，導致模型無法準確判斷文件是否能正確回答 Query

- **方法二：BGE m3 v2 Reranker（Encoder-only Transformer）：**
  第二種方法採用 **BGE m3 v2** 作為 reranking 模型，屬於 **Encoder-only Transformer 架構**。該模型將 Query 與 Document 直接拼接後進行編碼，並以回歸方式輸出文件與查詢之間的相關性分數。
  其運作方式如下：

  – **輸入格式：**

$$[CLS]Query[SEP]Document[SEP]$$

  – **輸出方式：**
    取 CLS token 的 hidden state，經線性層後輸出 raw relevance score

對應的打分形式可表示為：

$$\text{score}(q, d) = \mathbf{w}^\top \mathbf{h}_{\text{CLS}} + b$$

BGE m3 v2 的主要特性包括：

- **不受 prompt 設計影響**，排序結果穩定
- 對法律文本與技術文件等結構化內容表現更好
- 推論速度快，適合對 Top-K 候選文件進行 reranking

- **模型選擇與決策說明：**
  綜合實驗結果與實務考量，本專案最終選擇 **BGE m3 v2** 作為系統的 Reranker，主要原因如下：

  1. **排序穩定性較高**
     相較於 LLM-based classifier，BGE 不依賴 prompt，能提供一致且可重現的排序結果。
  2. **更符合 Chunk-level 法律文件檢索需求**
     法律條文本身語義明確，重點在於精準匹配條文內容，而非開放式推理，BGE 的語義相關性建模更為適切。
  3. **計算效率與系統延遲可控**
     在 Top-100 候選文件上進行 reranking 時，BGE m3 v2 能在效能與準確性之間取得良好平衡。

- **總結：**
  本專案於 Reranking 階段比較了 **LLM-based（Qwen3 4B）**與 **Encoder-based（BGE m3 v2）**兩種不同取向的方法。最終基於穩定性、效率與法律文本適配性考量，選擇 **BGE m3 v2** 作為主要 Reranker，有效提升檢索結果的精確度，並為後續生成階段提供更可靠的 Reranker，其結果展示如下圖 2所示。

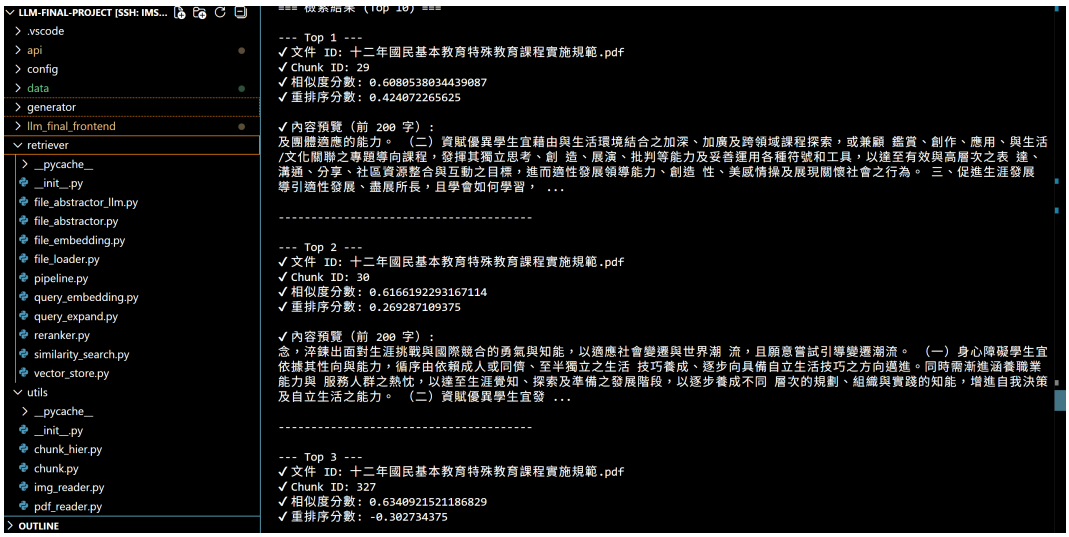


圖 2: 系統檢索結果

3.2 Generator（生成器)

3.2.1 Prompt Engineering

在生成式模型應用於 Retrieval-Augmented Generation（RAG）系統時，Prompt Engineering 對於生成結果的穩定性、可控性與專業一致性具有關鍵影響。在這次專題的 Prompt 設計上，參考 ReAct: Synergizing Reasoning and Acting in Language Models [4] 這篇論文所提出的核心概念，即透過明確的指令結構，引導模型在「推理（Reasoning)」與「行動（Acting)」之間取得平衡。

然而，考量本專案應用場景為**特殊教育相關法規與專業文件**，若直接採用顯性 Chain-of-Thought 或自由推理機制，可能導致模型產生過度推論、主觀解釋，甚至引用不存在的法規內容。因此，本專案並未完整暴露 ReAct 的推理步驟，而是**保留其「結構化控制」精神，並對生成行為施加嚴格約束**。

- **目標設計**

  Prompt Engineering 的主要設計目標如下：

  1. **確保回答內容嚴格依據檢索文件**
  2. **避免模型進行臆測或補充未出現於文件中的資訊**
  3. **符合特殊教育與法律應用對可驗證性與專業性的要求**
  4. **維持回答語氣自然、清楚，適合實際使用情境**

- **System Prompt 設計：**

  本專案採用固定且高度約束的 System Prompt，作為生成階段的行為規範，其內容如下：

  – **【角色設定】**

  你是一位能清楚回答問題的中文助手。你的核心任務是根據下面提供的「文件內容」，嚴格遵循【回答規則】來回答問題。你必須嚴格遵守以下「思考 (Thought) -> 行動 (Action)」的格式輸出：

  – **【Thought】**

  1. 目的分析分析使用者提出的問題，確定回答需要提取哪些關鍵資訊和法規細節。
  2. 資訊檢索計畫 (Acting/Action Planning):** 根據問題關鍵字，列出需要在「文件內容」中檢索的具體檔名（例如《特殊教育法.pdf》）和法條（例如第 X 條）。
  3. 資訊彙整與驗證 (Observation/Data Processing):** 從檢索到的文件中提取所有相關資訊，確認這些資訊是否完整、是否足以回答問題，並標記出所需的引用來源（檔名）。
  4. 答案建構 (Final Synthesis):** 依據驗證後的資訊，構建最終答案，並確保答案完全符合【回答規則】中的所有限制（特別是不可編造、必須引用來源、只回答一次）。

  – **【回答規則】**

  1. 回答只能依據文件內容，不可編造。
  2. 引用來源時必須明確寫出檔名，例如《xxx.pdf》。
  3. 不可引用未出現在文件列表中的檔名。
  4. 若文件沒有答案，請直接回答：「文件裡沒有提到相關資訊」。

5. 回答要自然、簡單、一般中文口吻即可。
6. Final Answer 區塊只回答一次，不得重複或加入多餘說明。
7. Thought 區塊必須完整推理，但不得在 Final Answer 中重複內容。

- **與 ReAct 方法的關係與取捨：**
  ReAct 論文強調模型在推理過程中結合外部行動（如搜尋、查詢工具），並透過顯性推理軌跡提升問題解決能力。然而，在本專案的應用情境中：

  – **推理內容本身不應成為輸出的一部分**
  – **模型的任務是「整理與轉述文件內容」，而非「自行推導答案」**

  因此，本專案將 ReAct 的概念轉化為「**行為約束式 Prompt Engineering**」，具體作法包括：

  – 不要求模型輸出推理過程
  – 不允許模型跨文件或補充背景知識
  – 明確規定「無答案時的標準回覆格式」
  – 限制回答次數與語句冗餘，避免生成發散

  此設計使模型在生成階段僅扮演「**受控的文件解讀者**」，而非開放式的知識推理者，從而提升整體系統在法律與特殊教育場景中的可靠性。

- **小結：**
  本專案在 Prompt Engineering 上，雖參考 ReAct 所提出的推理與行動協同概念，但並未直接採用顯性推理輸出，而是根據實務需求進行收斂與約束。透過嚴格定義的 System Prompt，本系統能在維持生成穩定性的同時，確保回答內容可追溯、可驗證，並符合特殊教育專業應用的實際需求。

3.2.2 IEP Prompt Template

相較於一般法規查詢或問答型任務，**IEP（Individualized Education Program）制定屬於高度結構化、專業導向且具責任歸屬的生成任務**。其輸出內容不僅需正確引用法規與課綱，更需符合台灣特殊教育實務中對「可觀察、可評量、可執行」的要求。因此，本專案針對 IEP 任務，額外設計一套**專用的 Prompt Template**，以確保生成內容在專業性、邏輯性與可驗證性上的一致。

- **IEP Prompt Template 所涵蓋欄位**
  本專案設計的 IEP Prompt Template，完整涵蓋台灣教育現場常見之 IEP 核心欄位，包含：

  1. **現況能力分析**
  2. **學期目標（SMART 原則）**
  3. **教學策略**
  4. **評量方式**
  5. **RAG 查詢結果引用**
  6. **多障別差異化需求**

透過明確規定欄位結構，可避免模型遺漏關鍵資訊，並使生成結果可直接對應實務使用情境。

- **System Prompt 的角色與任務設定：**
  在 IEP 任務中，本專案使用高度具體的**角色型 System Prompt**，明確界定模型的專業身分與知識範圍：
  - 角色被限定為「具備台灣特殊教育專業的 IEP 制定專家」
  - 明確指定可依據之法規與課綱來源，包括：
    - 《十二年國民基本教育身心障礙相關之特殊需求領域課程綱要》
    - 《十二年國民基本教育高級中等教育階段學校集中式特殊教育班服務群科課程綱要》
    - 《十二年國民基本教育特殊教育課程實施規範》
  - 明確涵蓋多障別教育需求（視障、聽障、自閉症、學習障礙）此設計可有效限制模型的知識邊界，降低生成與台灣教育制度不符內容的風險。

- **Thought–Action–Observation 結構化生成設計：**
  與前一節一般問答型 Prompt 不同，**IEP Prompt 明確要求模型輸出結構化的推理與行動流程**，其原因在於 IEP 制定本身即為一項「可被檢核的專業決策過程」。本專案改寫後的 ReAct 架構，要求模型針對每一個主要 IEP 欄位，皆依以下格式輸出：
  - **【專家思考（Thought）】**
    此區段不作為最終 IEP 文件的一部分，而是用於：
    - **資料分析**：辨識學生資料中支持該欄位撰寫的具體行為或數據
    - **課綱對照**：對應至具體的課程綱要領域或學習表現
    - **策略制定**：將教育目標轉換為符合 SMART 原則的描述
  - **【IEP 撰寫（Action）】**
    此區段為實際輸出的 IEP 正式內容，需：
    - 採用教育現場可直接使用的語言
    - 保持具體、可觀察、可操作
    - 嚴格依據 Thought 區段所推導的結論生成
  - **【查詢結果（Observation）】**
    Observation 區段專門用於呈現 **RAG 系統回傳的課綱或法規原文內容**，其設計原則包括：
    - 僅能呈現檢索到的原文
    - 不允許模型自行改寫或補充
    - 不得捏造不存在的課綱條文

    此設計可將「生成內容」與「依據來源」清楚分離，提升整體可追溯性。

- **作業規範與風險控制：**
  為避免生成內容在法律與教育專業上產生風險，本專案於 Prompt 中明確加入以下限制條款：

- **禁止捏造醫療資訊、診斷或視力／聽力數據**
- 若學生資料不足，必須以「未提供」標示，不可自行補齊
- 所有欄位皆需產生，不得省略

此類明確規範能有效降低 hallucination 風險，並確保生成內容符合實際教育行政文件的標準。

- **小結：**
  本專案針對 IEP 制定任務，設計了一套結合**角色約束、欄位模板與 ReAct 結構化輸出**的 Prompt Template。透過 Thought–Action–Observation 的分層設計，不僅提升生成內容的專業一致性，也使每一項 IEP 建議具備明確的資料與課綱依據，符合台灣特殊教育現場對 IEP 文件的實務需求。

3.3 Context Memory（上下文記憶）

在 IEP（Individualized Education Program）制定過程中，使用者往往需要透過**多輪對話**逐步補充學生背景資料、修正目標描述或調整教學策略。若系統無法有效保存先前輪次所提供的學生資訊，將導致模型在後續回合中遺失關鍵上下文，進而產生前後不一致的分析結果，影響 IEP 文件的整體連貫性與專業性。

為解決上述問題，本專案在系統架構中導入 **Context Memory（上下文記憶）機制**，以支援長時間、多輪互動下的穩定生成。

3.3.1 記憶模組設計概念

本專案將記憶機制區分為三個層級，分別對應不同時間尺度與用途：

1. **學生資料永久記憶（Profile Memory）**
   Profile Memory 用於儲存與學生本身高度相關、且在整個 IEP 制定過程中需反覆被引用的核心資訊，例如：

   - 學生基本背景資料（年級、教育安置類型等）
   - 障別類型（視障、聽障、自閉症、學習障礙等）
   - 長期不易變動的教育需求描述

   此類資料一經確認後，將被視為「準靜態資訊」，在後續所有生成與分析階段中皆可被模型引用，避免使用者於每一輪對話中重複輸入相同內容。

2. **對話多輪記憶（Multi-turn Memory）**
   Multi-turn Memory 用於保存近期對話中所產生的互動內容，包括：

   - 使用者針對 IEP 欄位的補充說明
   - 已生成之現況能力分析、學期目標或教學策略
   - 教師對模型輸出結果的修正或回饋

   透過此機制，模型能在後續輪次中延續先前的討論脈絡，使新生成內容能自然銜接既有 IEP noticed，避免重複或矛盾。

3. **記憶管理策略**
   為在系統效能與上下文完整性之間取得平衡，本專案設計記憶管理策略如下：

   - **僅保留最近 10 組對話紀錄**作為有效 Multi-turn Memory
   - 較舊的對話內容將被自動捨棄，避免上下文過長影響推論效率
   - Profile Memory 與 Multi-turn Memory 明確區分，避免學生核心資料被誤刪

   此策略可在不犧牲系統回應速度的前提下，維持足夠的對話上下文資訊。

3.3.2 Context Memory 對 IEP 任務的影響

導入 Context Memory 後，系統在 IEP 任務中展現出以下明顯優勢：

1. **維持 IEP 格式與內容的一致性**
   各欄位生成結果能延續既有學生資料與目標設定，避免前後矛盾。

2. **降低使用者操作負擔**
   降低使用者操作負擔教師無需重複輸入學生背景與障別資訊，提升使用體驗。

3. **支援漸進式 IEP 制定流程**
   系統可配合實務流程，逐步完成現況分析、目標設定與評量設計。

3.3.3 小結

Context Memory 機制使本系統不再僅是一個單輪問答式的生成模型，而是能支援**多輪次、結構化 IEP 制定流程的輔助工具**。透過 Profile Memory 與 Multi-turn Memory 的分層設計，以及適當的記憶管理策略，模型得以在多輪互動中維持 IEP 格式與內容的連貫性，進一步提升系統於特殊教育實務場域中的可用性與可靠性。

4 Experiments

4.1 Dataset

目前公開可用之 Retrieval-Augmented Generation（RAG）資料集，多集中於開放領域問答、維基百科或一般知識檢索任務，**尚無針對台灣特殊教育（IEP、特教法規、課綱）情境設計的標準 RAG benchmark**。由於特殊教育屬於高度在地化且具法規依據的專業領域，直接套用既有通用資料集，無法真實反映實務應用中對「法規正確性」與「文件可追溯性」的要求。

因此，本專案選擇自行建構一個**小型、任務導向的特教領域 RAG benchmark**，以作為系統效能驗證之基礎。

4.1.1 資料來源

資料集內容主要蒐集自下列具權威性與實務代表性的來源：

- **優質特教網**
  - 特教教材資料庫

  - 教學輔助與實務案例內容

- **特殊教育相關法規**
  - 《特殊教育法》
  - 相關施行細則與行政規範

- **線上特教教材與教學資源**
  - 教教材與教學資源與課綱直接相關之公開教材內容

4.1.2 資料結構設計

為符合 RAG 任務特性，本專案將資料集設計為三元組結構：

- **學生提問（Query）**
  模擬教師或教育人員在實務中可能提出的問題，例如對課程調整、支持服務或法規規範的查詢。

- **對應教材或法規段落（Document / Passage）**
  與該問題具直接對應關係的教材內容或法規條文，作為檢索與生成的依據文件。

- **標準答案（Ground Truth Answer）**
  由研究者根據文件內容人工整理之正確回答，作為模型評估的比對基準。

此結構可同時用於評估**檢索階段（是否找對文件）**與**生成階段（是否正確引用並回答）**的整體效能。

4.1.3 資料集規模

考量資料整理與人工驗證成本，本專案目前建構之資料集規模為：

- **52 筆問答樣本**

雖屬小型 benchmark，但能涵蓋多種類型的特教實務問題，適合用於系統設計驗證與方法比較。

4.1.4 驗證與評估方式

由於本專案應用場景涉及法規與特殊教育專業內容，**對錯誤回答的容忍度極低**。因此，在評估方式上，本專案採用人工驗證（Human Evaluation），並設定嚴格的正確性標準：

- 模型回答內容**必須與預設標準答案一致，不可多回答或少回答**

- 回答內容需：
  - 正確描述法規或教材重點
  - 未加入額外未出現於文件中的資訊
  - 無語意偏差或錯誤解釋

僅當模型回答「完全命中」標準答案時，才視為該題回答正確；否則一律判定為錯誤。此評估方式雖較為嚴格，但能更真實反映特教與法規應用場景中對正確性與可驗證性的實際需求。

4.1.5 小結

由於缺乏公開的特教領域 RAG 資料集，本專案自行建構一個小型但高度任務導向的 benchmark，作為系統實驗與驗證基礎。透過嚴謹的資料來源選擇、明確的資料結構設計，以及人工完全命中的評估標準，本資料集能有效檢驗系統在特殊教育場景中的實用性與可靠性。
完整的表單與實驗結果：`https://pse.is/8g35q5`

4.2 實驗對象與 Ablation Study

為驗證本專案所提出之 RAG 系統架構與 Prompt Engineering 設計對特教領域任務的實際效益，本專案規劃多組實驗設定，進行系統性比較與 Ablation Study。實驗重點在於分析 **RAG 機制、Prompt Engineering 與模型本身能力**，各自對最終回答正確性的影響。

4.2.1 實驗對象說明

本專案共設計五組實驗對象，說明如下。

1. Qwen3-4B + RAG + Prompt Engineering（完整系統）
   此設定為本專案提出之**完整系統架構**，結合：
   - File Abstracting 與 Chunking
   - Qwen3 Embedding + FAISS 向量檢索
   - BGE m3 v2 Reranker
   - ReAct-inspired Prompt Engineering
   - IEP 專用 Prompt Template
   - Context Memory（Profile Memory + Multi-turn Memory）

   此組結果作為主要比較基準，用以驗證整體系統在特教領域 RAG 任務中的實際表現。

2. Qwen3-4B + RAG（移除 Prompt Engineering）
   此設定保留完整的 RAG 檢索與文件提供流程，但**移除 Prompt Engineering Module**，改以簡單、無結構約束的生成提示進行回答。
   透過此組實驗，可評估：
   - Prompt Engineering 對回答正確性與穩定性的影響
   - 是否僅依賴 RAG 檢索即足以產生專業、可驗證的回答

3. Qwen3-4B（Base Model）
   此設定僅使用 **Qwen3-4B 基礎語言模型**，不提供任何外部文件或檢索結果，屬於純生成情境。
   此組實驗主要用於檢驗：
   - 僅依賴模型內部知識時的表現上限
   - 模型是否會產生幻覺（hallucination）或不符合特教法規的回答

4. AIDE / LLaMA（台灣資料微調模型）
   此設定採用**以台灣語料進行特別 fine-tune 的 TAIDE / LLaMA 系列模型**，作為「在地化模型」的代表。
   透過此組實驗，可觀察：

   - 僅透過在地資料微調，是否足以應對特教法規與教材查詢任務
   - 與結合 RAG 架構的模型相比，其在可驗證性與正確性上的差異

5. GPT-5.1 mini（通用大型語言模型）
   此設定選用 GPT-5.1 mini 作為對照組，代表目前實務中**最常被一般使用者採用的通用大型語言模型**。
   此組實驗的目的在於比較：

   - 通用大型語言模型在未特別針對特教任務設計下的實際表現
   - 專用 RAG 系統是否能在專業領域任務中超越通用模型

4.2.2 Ablation Study 設計重點

本專案的 Ablation Study 主要聚焦於以下三個面向：

- RAG 機制的必要性
  比較 1.、2. 與 3.，分析外部文件檢索對回答正確率的影響。

- Prompt Engineering 的貢獻
  比較 1. 與 2.，驗證結構化 Prompt 是否能顯著提升模型在特教任務中的穩定性與可控性。

- 專用系統 vs 通用模型 / 在地化模型
  比較 1.、4. 與 5.，評估專為特教任務設計之 RAG 系統，是否能在專業性與可靠性上優於通用或僅微調模型。

4.2.3 小結

透過上述多組實驗設定與 Ablation Study，本專案得以系統性地分析各個模組在整體系統中的實際貢獻，並驗證「**結合 RAG 與結構化 Prompt Engineering 的專用系統**」在特殊教育應用場景中的必要性與優勢。

4.3 Expert Assessment

為評估系統在真實教育場域的實用性，本專案邀請特殊教育相關領域之教師與專家進行人工評估。其中包含：

- 交大資源教室 4 位教師進行訪談
- 以線上表單邀請多位特教老師與領域專家進行評分

本專案採用情境式盲測評估（scenario-based blind evaluation）以比較不同大型語言模型在 IEP 生成任務中的表現。首先，本專案建構一組統一的學生情境背景，包括年級、障礙類別、語言溝

通、社交行為、情緒反應與學習特質等，作為所有模型生成內容的共同依據，如圖 3所示。

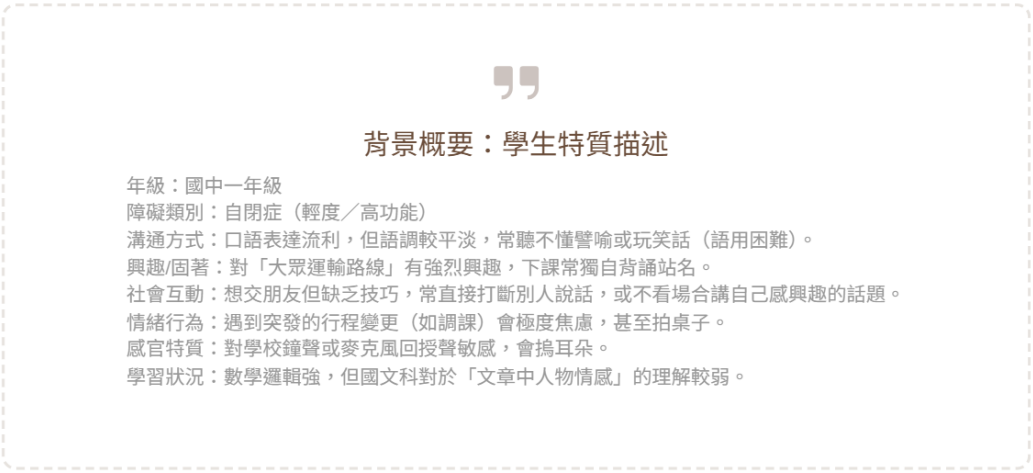


圖 3: 表單設計之背景概要內容

將此情境使用三種語言模型生成 IEP 內容建議，語言模型選擇為：

1. 版本一：Gemini 3 Pro
2. 版本二：Qwen4B + RAG + Prompt Engineering（本專案成果）
3. 版本三：GPT5-mini

三個模型皆需根據情境資料與課綱要求，生成可用於 IEP 的學習目標與相關指標。為避免受試者產生偏誤，三版本的內容均以隨機順序呈現，不標示來源模型，形成盲測評比，如圖 4所示。

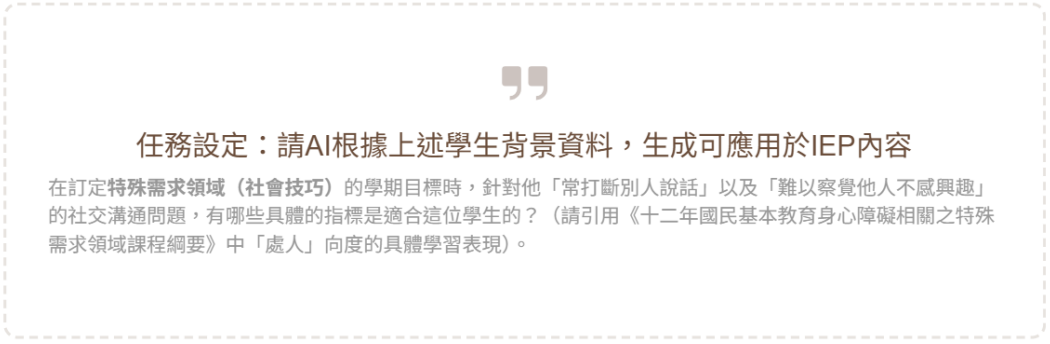


圖 4: 表單設計之任務設定內容

三個語言模型生成結果：`https://hackmd.io/@RuoWei/Hk45yIPGbg`

受試者需閱讀三版本產出，並根據五項指標（可量化性、專業度、法規引用正確性、結構與可讀性、實務可用性）以 Likert 量表評分，如圖 5所示，並對三版本進行整體排序，如圖 6所示。最後，受試者亦提供開放式回饋，以補充定量結果之解釋，。



圖 5: 表單設計之問題評分



圖 6: 針對三個版本的整體內容進行排序

完整表單：`https://www.surveycake.com/s/aMzkK`

5 Results

5.1 實驗結果與分析

本節說明各實驗對象在自建特教領域 RAG benchmark 上的定量實驗結果，並進一步說明為何部分模組（特別是 Prompt Engineering）的效益，無法僅透過 Accuracy（ACC）指標完整反映。

5.1.1 定量實驗結果

表 1顯示不同模型與系統設定在本專案資料集上的實驗結果。

表 1: Performance comparison of different LLM settings

	Qwen4B + RAG + PE	Qwen4B + RAG	Qwen4B	taide/LLaMA	GPT
1	47	47	5	9	12
0	5	5	47	43	40
ACC	0.90385	0.90385	0.09615	0.17308	0.23077

5.1.2 結果觀察

從上述結果可觀察到以下幾點關鍵現象：

1. **RAG 架構對正確率具有決定性影響**
   與不使用外部文件的 Base Model 相比，加入 RAG 後，Qwen3-4B 的 Accuracy 從 0.09615 大幅提升至 0.90385，顯示在特教與法規任務中，外部文件檢索是必要條件。

2. **通用模型與在地化模型表現仍顯不足**
   即便 GPT 與 TAIDE / LLaMA 具備較強的語言能力或在地語料微調，其在完全命中標準下的 ACC 仍明顯低於 RAG 系統，顯示僅依賴模型內部知識不足以應對高度專業、可驗證的特教任務。

3. **Prompt Engineering 在 ACC 指標上未呈現差異**
   在「Qwen3-4B + RAG」與「Qwen3-4B + RAG + Prompt Engineering」兩組設定中，兩者的 Accuracy 數值完全相同，皆為 0.90385。

為何 Prompt Engineering 無法直接反映於 Accuracy?

上述結果並不代表 Prompt Engineering 無效，而是源於本專案所採用的評估指標特性。
在本專案中，**Accuracy 採用「完全命中（Exact Match）」的人工驗證方式**，僅檢查模型是否回答正確、是否命中標準答案，而**不評估回答的結構品質、語氣專業性或可操作性**。
然而，Prompt Engineering 的主要作用在於：

- 強化回答的結構完整性（如 IEP 欄位齊備）
- 降低語意模糊與過度發散
- 提升專業語氣與實務可用性
- 確保引用格式與回應規範一致

這些改進**不一定會影響「對 / 錯」的判定結果**，但對實際教育現場的使用價值具有關鍵影響。因此，本專案將 Prompt Engineering 的效益，另行交由 **Expert Assessment（專家人工評估）**進行判斷。在第二階段評估中，將由具備實務經驗的**特殊教育教師**，針對模型輸出進行質性評估，評估面向包括：

- 回答是否符合特教專業語境
- IEP 欄位是否完整且合理
- 教學策略與目標是否具體、可執行
- 回答是否具有實務可用性

透過專家評估，本專案得以補足單一定量指標無法反映的「輸出品質差異」，更全面地衡量 Prompt Engineering 的實際貢獻。

5.1.3 小結

整體而言，定量實驗結果證實 **RAG 架構對特教領域問答任務具高度必要性**。而 Prompt Engineering 的價值，則主要體現在輸出內容的專業度與結構合理性，需透過 Expert Assessment 等質性評估方式加以驗證，無法僅依賴 Accuracy 指標衡量。

5.2 Expert Assessment Result

5.2.1 Prompt Engineering 有效性評估

在進行定量實驗分析之前，本專案首先邀請四位具實務經驗之特殊教育教師，針對系統是否採用 Prompt Engineering 對 IEP 撰寫的實際輔助效果進行初步專家評估。評估過程中，教師僅比較「加入 Prompt Engineering」與「未加入 Prompt Engineering」兩種系統輸出，並在不知模型內部設計細節的情況下，判斷哪一種輸出結果較能有效協助 IEP 的撰寫與實務應用。

評估結果顯示，四位特教教師一致認為，加入 Prompt Engineering 的系統輸出在結構完整性、專業用語適切性，以及 IEP 欄位撰寫的實務可行性上，皆明顯優於未加入 Prompt Engineering 的版本。因此，本專案後續的 Expert Assessment 比較中，將以「Qwen3-4B + RAG + Prompt Engineering」之輸出結果，作為本專案的主要系統成果，並與其餘實驗對象進行比較與分析。

5.2.2 交大資源教室老師評估

在確認加入 Prompt Engineering 之系統輸出較具實務價值後，本專案進一步將其作為代表性成果，與其他主流大型語言模型進行比較。此階段的 Expert Assessment 比較對象包含三個版本：(1) **Gemini 3 Pro**、(2) **Qwen3-4B + RAG + Prompt Engineering（本專案成果）**，以及 (3) **GPT-5 mini**。評估同樣由具備實務經驗之專業人員進行，並以 IEP 撰寫的實際可用性作為主要判斷依據。

表 2評估結果顯示，**國立陽明交通大學資源教室之特教專業人員一致認為，版本二（Qwen3-4B + RAG + Prompt Engineering）所產生的輸出內容在法規對照完整性、條文引用正確性，以及 IEP 欄位撰寫的合理性上，皆優於 Gemini 3 Pro 與 GPT-5 mini**。相較於通用大型語言模型，版本二能更明確對照實際的特殊教育法規與課綱內容，並產出較符合高中階段特殊教育教師實務需求的 IEP 建議，顯示本專案所提出之系統設計在真實教育場域中具備較高的輔助價值。

5.2.3 盲測表單評估

在盲測表單評估中，我們用問卷調查、實地訪談了交大資源教室、教育現場老師、特教專業背景人員，多數教師將「**版本二（本專案成果）**」評選為最符合實務需求的生成內容。相較之下，版本一與版本三較少被選為最佳，其中教師回饋普遍指出，**版本一需要進行最多後續人工修改**。整體而言，版本二所產生的內容較貼近真實 IEP 撰寫流程，因其具備可直接引用的段落設計與明確對應課綱之指標，能有效降低教師後續調整的負擔。

表 2: 不同版本 IEP 撰寫輔助系統之評估結果

評估指標	**版本一**	**版本二**	**版本三**
目標設計明確、可量化	3.00	3.17	3.17
回答內容展現出特殊教育的深入理解	3.50	3.17	3.17
正確引用課程綱要、正式法規文件	2.00	4.50	2.50
內容層次分明、容易閱讀與理解	3.50	3.50	3.50
符合實務需求，可以直接應用於 IEP 撰寫	2.83	3.50	2.83
整體平均分數	2.966	**3.568**	3.034

在 **Likert 量表五項評分指標**中，版本二於「**正確引用課程綱要、正式法規文件**」一項獲得 **4.5 分**，明顯高於版本一（2.0 分）與版本三（2.5 分），顯示本專案結合 RAG 與 Prompt Engineering 的設計，能有效引導模型產生具備明確法規依據且可查證的內容。此一面向亦為教師在實務撰寫 IEP 時最為重視的關鍵因素之一。

此外，版本二在「**符合實務需求，可以直接應用於 IEP 撰寫**」之評分（3.5 分）亦高於版本一與版本三（皆為 2.83 分），反映教師普遍認為版本二的內容在結構與表述上較能直接作為 IEP 撰寫之基礎草稿。雖然三個版本在「內容層次分明、容易閱讀與理解」此一指標上得分相同（皆為 3.5 分），但版本二在法規引用正確性與整體可用性上仍展現出明顯優勢。

另外在教師針對版本二的開放式**質性回饋**中，看了以下共同特點：內容最貼近真實 IEP 寫作風格、提供的目標與指標符合課綱指引，不用人工來回對照等。綜合量化評分結果與質性回饋分析可知，**本專案所提出之系統架構（版本二）在人工專家評估中獲得最一致且明確的正向評價**，亦顯示其在特殊教育實際場域中具備高度應用潛力。

5.2.4 Demo & Github

- Demo 影片連結：`https://youtu.be/NlvRbcs7pFk`
- Github 專案連結：`https://github.com/vv-chang/Course-Final-Project.git`
- Benchmark 實驗結果連結：`https://pse.is/8g35q5`
- 三個語言模型生成結果：`https://hackmd.io/@RuoWei/Hk45yIPGbg`
- 完整盲測表單：`https://www.surveycake.com/s/aMzkK`



圖 7: 實際 Demo 結果展示之輸入學生基本資料



圖 8: 實際 Demo 結果展示之模型針對使用者問題進行分析



圖 9: 實際 Demo 結果展示之模型提供的回答統整

6 Conclusion

透過本次專案，我們成功建立了一套專為特殊教育領域打造的 IEP 撰寫輔助生成系統，能同時做到「找到正確資料」以及「生成高品質內容」。在前期準備中，我們蒐集並整理《特殊教育法》、《十二年國教課程綱要》、IEP 範例、教材、paper 等資料，構建成向量化知識庫，使模型能在生成前檢索可靠且具依據的內容。

在系統開發方面，我們完成了前後端整合，並將 LLM 導入 RAG 架構，同時設計多項實驗與測評流程，以驗證系統在準確性、可用性與專業度上的表現。透過客製化 Prompt 與多輪對話記憶，模型能更好地理解不同障礙類別的需求，生成可實際應用的 IEP 目標、教學調整與評量方式，使內容更貼近真實教育現場。這次專案也讓我們更深刻理解特殊教育領域的價值與挑戰。並在未來持續完善模型及優化流程架構及擴充資料庫等，探索更多大型語言模型於專業領域之應用面向。

參考文獻

[1] Chen, Z., Liu, J., Xiao, Y., Wang, Z., & Zhang, Y. (2024). *HiChunk: Evaluating and Enhancing Retrieval-Augmented Generation with Hierarchical Chunking.* arXiv preprint arXiv:2403.09755.

[2] Xiao, S., Liu, Z., Shao, X., & Zhang, Y. (2024). *M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation.* arXiv preprint arXiv:2402.03216.

[3] Zhang, Y., Li, M., Long, D., Zhang, X., Lin, H., Yang, B., Xie, P., Yang, A., Liu, D., Lin, J., Huang, F., & Zhou, J. (2025). *Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models.* arXiv preprint arXiv:2506.05176.

[4] Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). *ReAct: Synergizing Reasoning and Acting in Language Models.* Proceedings of the 11th International Conference on Learning Representations (ICLR 2023), Kigali, Rwanda.